Report

Sommario

Report 1
Introduction 2
Tecnical Tasks 2
Data cleaning 2
Data analisis 3
Data visualization 5
Conclusion 6
Division of work 6
Extra Information 6
Bibliography 6

Introduction

All'interno di questo resoconto analizzeremo in modo dettagliato tutte le fasi dell'analisi dei dati e come l'abbiamo affrontata. Come metodo di analisi abbiamo deciso di dividere i set di dati in due diversi set, i dati statici e i dati dinamici, segue elenco.

Dati statici: Club, Competitions, Players
Dati dinamici: Appearances, Club_games, Game_events, Game_lineups, Games, Player_valutations,

Questa analisi è stata fondamentale per la divisione dei dati all'interno del database, per la divisione del lavoro e la gestione dello stesso.

I dati statici sono quelli su cui abbiamo apportato una prima analisi generale. Questo è servito per comprendere il collegamento tra i diversi set di dati, fare esperimenti con Jupyter notebook e i grafici più semplici e su cui abbiamo deciso di svolgere, principalmente, pulizia e analisi con una piccola rappresentazione basilare.

I dati dinamici sono invece quelli che riteniamo essere i dati più importanti nel nostro campo di ricerca. Nell'ambito delle analisi calcistiche il numero di goal di un giocatore, le sostituzioni fatte, i rigori segnati, sono i dati su cui vengono svolte più ricerche e che da soli possono rappresentare molto su una squadra. E' quindi su questa parte che la nostra analisi è andata più in profondità, non soffermandosi solamente su pulizia e una prima analisi e visualizzazione, ma su ricerche più approfondite e su rappresentazioni visuali più interessanti.

Abbiamo scelto questo metodo di analisi anche per evitare di ripetere le stesse ricerche incrociate, essendo necessario il merge tra diversi set di dati. Consideriamo per esempio il dataset Goal e Player, sarà necessario fare un merge per avere più informazioni sul giocatore che ha fatto goal. Le stesse analisi potrebbero essere fatte in entrambi i notebook, ma secondo la nostra scelta progettuale, verrà fatta nel notebook di Goal.

Tecnical Tasks

All'interno dell'analisi dei dati sono 3 i compiti principali necessari per un'analisi completa ed efficace: - pulizia dei dati -analisi/comprensione dei dati -visualizzazione dei dati

Data cleaning

Solution

Abbiamo implementato il data cleaning all'inizio di ogni analisi di un data set tramite:

- Creazione di sotto tabelle per limitare il numero di dati
- Inserimento di un indice interessante per il dataset
- Eliminazione dei duplicati

```
#le colonne che seleziono sono quelle che posso considerare più utili nell'analisi dei dati di un giocatore. Devo sicuramente
#conoscerne l'id, il nome, la data di nascita per avere il backgound; inoltre l'ultima stagione giocata e cittadinanza (scelta in
#al posto di Stato di nascita perché possono essere diverse) possono essere usati per la ricerca del giocatore. Altezza, valore di mercato,
#massimo valore di mercato e piede usato sono ottimi valori su cui analizzare i calciatori

df=players_df[['player_id','name','last_season','country_of_citizenship','date_of_birth', 'sub_position', 'position',
       'foot', 'height_in_cm', 'market_value_in_eur', 'highest_market_value_in_eur',]]
df=df.set_index('player_id')
df=df[~df.duplicated()]
df
```

Figura 1: esempio preso dall'analisi di Player

- Eliminazione dei valori nulli per colonne, in modo tale che solo i "valori chiave" nell'analisi non siano nulli

```
#Ora analizziamo i valori di mercato dei calciatori. Voglio controllare se sono presenti dei calciatori con 'market_value_in_eur' e
#'highest_market_value_in_eur' non nullo. Sono effettivamemte presenti, in questo modo posso sostituire il valore di mercato con il massimo
#valore offerto essendo l'unico dato a noi disponibile su quel giocatore
no_market_value=df[df['market_value_in_eur'].isna()&~df['highest_market_value_in_eur'].isna()]
no_market_value
```

Figura 2: esempio preso dall'analisi di Player

- Eliminazione di valori outlier e ricerca dei dati inconsistenti

```
#Controllo chi è più basso di 150 cm (altezza accettabile). Sono presenti due giocatori con altezza errata di 18 cm. Non può
#essere logicamente un'altezza in piedi, potrebbe essere un errore di battitura (1.8 m invece che 18 cm), ma essendo solo due casi
#vengono eliminati
out=df[df['height_in_cm']<150]
out
```

player_id	name	last_season	country_of_citizenship	date_of_birth	sub_position	position	foot	height_in_cm	market_value_in_eur	highest_market_value_in_eur
592398	Aïssa Boudechicha	2021	Algeria	2000-04-13	Left-Back	Defender	left	18.0	150000.0	150000.0
628490	Genar Fornés	2021	Spain	2000-01-17	Left-Back	Defender	left	18.0	150000.0	150000.0

Figura 3: esempio preso dall'analisi di Player

Issues

Sono stati due i problemi che abbiamo riscontrato durante la pulizia:

1. Presenza di dati non parlanti o riconoscibili, ciò poteva far sembrare dei dati validi nulli e viceversa. Due esempi citabili sono:
    a. il valore -1 nel dato 'minute' di Game_events, inizialmente riconosciuto come dato nullo/non conosciuto, ma in realtà dato inserito per tutti i calci di rigore
    b. Il valore +-0 nel dato 'net_transfer_record', inizialmente riconosciuto come dato valido (bilancio neutro), ma che in seguito abbiamo dovuto cancellare poiché non avendo unità di misura (€) e avendo il doppio simbolo (+-) non permetteva la ricerca agile dei club con maggiori guadagni
2. Presenza di dati in un alfabeto diverso, in particolare il cirillico. Abbiamo fatto una ricerca approfondita per trovarli in due diversi notebook, ma essendo la squadra una sola abbiamo deciso in altri notebook di mantenerlo.

Requirement

Per quanto riguarda le richieste di pulizia di dati, abbiamo svolto una buona analisi di base, togliendo la maggior parte dei problemi e concentrandoci anche sull'osservazione degli outlier. Immagino che siano però rimasti alcuni dati errati per quanto riguarda alcuni specifici dati, dovuti anche a una nostra ignoranza in ambito calcistico. Un esempio riguarda i valori di mercato, non avendo conoscenza abbiamo dato per scontato che essendo elevati e positivi fossero giusti.

Limitations

Avendo fatto analisi modulari per gestire una minor quantità di dati, la pulizia rimane all'interno del notebook e quindi per utilizzare i dati puliti all'interno di altre analisi bisognerebbe creare un nuovo csv. All'interno del nostro progetto non abbiamo seguito questo percorso, preferendo utilizzare i csv originali e mantenendo solo i dati essenziali e non nulli.

Quindi per esempio se un club X è stato eliminato all'interno dell'analisi di club perché aveva '+-0' nel net_transfer_record, potrebbe poi essere utilizzato in seguito nell'analisi dei club con più cartellini. Abbiamo fatto questa scelta progettuale anche per impedire che le analisi svolte su particolare campo fossero errate a causa di un campo non inerente (faccio un'analisi sui club con più cartellini, non mi interessa se di quel club non conosco il net_transfer_record).

Data analisis

Solution

Abbiamo implementato la data analisis tramite diverse tecniche, le principali sono:

- Utilizzo di describe, per trovare dati numerici errati o non parlanti, i valori di media, i massimi e i minimi per ottenere gli oulier

```
#tramite la descrizione riesco ad osservare il data_set totale. Da qui posso già notare che il numero di goal massimi è elevato
#provo a pulire i dati prima di considerarlo un errore
games_df.describe()
```

	game_id	season	home_club_id	away_club_id	home_club_goals	away_club_goals	home_club_position	away_club_position	attendance
count	6.477500e+04	64775.000000	64775.000000	64775.000000	64775.000000	64775.000000	45416.000000	45416.000000	55268.000000
mean	3.017716e+06	2017.251378	4925.401636	4444.039290	1.594519	1.322069	9.289832	9.472477	18102.623001
std	5.604905e+05	3.349040	11455.437124	10273.099127	1.428038	1.364267	5.303623	5.325440	17808.114723
min	2.211607e+06	2012.000000	1.000000	2.000000	0.000000	0.000000	1.000000	1.000000	1.000000
25%	2.518106e+06	2014.000000	354.000000	347.000000	1.000000	0.000000	5.000000	5.000000	4270.000000
50%	2.919811e+06	2017.000000	1003.000000	989.000000	1.000000	1.000000	9.000000	9.000000	12179.000000
75%	3.450780e+06	2020.000000	3205.000000	3030.000000	2.000000	2.000000	14.000000	14.000000	26307.250000
max	4.228114e+06	2023.000000	112753.000000	112755.000000	15.000000	19.000000	21.000000	21.000000	99354.000000

Figura 2:esempio preso dall'analisi di Games

- Utilizzo di scatter plot per visualizzare l'andamento dei dati, i grafici sono fondamentali per comprendere i dati essendo presente una mole importante di dati. Per esempio tramite lo scatter plot abbiamo capito che all'interno di Club_games i dati sono dal punto di vista di entrambe le squadre (i due scatter plot sono identici) e abbiamo modificato di conseguenza, eliminando e modificando i dati.
  I dati sono stati modificati come segue e presentato nel codice:
  "I dati potrebbero essere analizzati dimezzandoli senza perdere informazione. Togliamo tutte le squadre Away e togliamo la colonna hosting, in questo modo (anche togliendo il dato) possiamo ricavare in ogni caso l'informazione, poiché tutte le opponenti saranno esterne[...]"

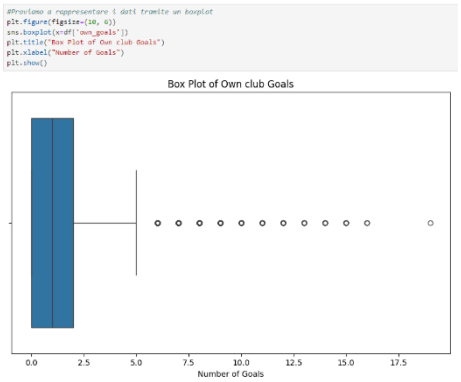


Figura 5: esempio di Club_games, goal della squadra principale

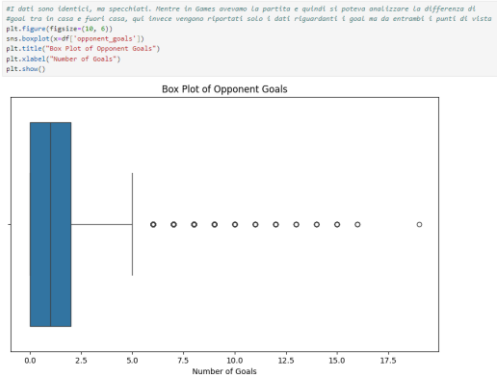


Figura 6: esempio di Club_games, goal della squadra avversaria

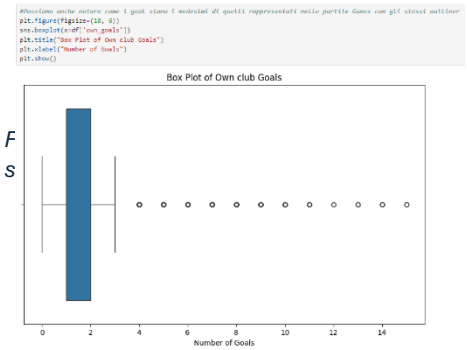


Figura 7:nuovo scatter plot squadra principale

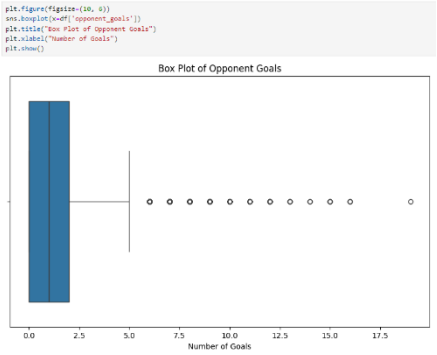


Figura 8:nuovo scatter plot goal squadra avversaria

- Tramite il merge tra diversi set di dati abbiamo potuto ricavare informazioni utili e rendere i nostri grafici parlanti. Un esempio si può vedere in Appearances dove abbiamo fatto il merge con Club e Competition per rappresentare quali club nelle competizioni europee ottengono più cartellini.

```
#voglio analizzare il rapporto tra le competizioni, le squadre e i cartellini. Per fare questo
#pulisco i dati togliendo quelli con competition_id null, faccio una join con le competizioni e le squadre

cards_df = df[~df['competition_id'].isna()]

club_df=pd.read_csv('clubs.csv')[['club_id', 'name']]
competition_df=pd.read_csv('competitions.csv')[['competition_id', 'country_id', 'name', 'country_name']]

merged_df=pd.merge(cards_df, club_df, left_on='player_club_id', right_on='club_id')
merged_df = merged_df.rename(columns = {'name': 'club_name'})

merged_df=pd.merge(merged_df, competition_df, left_on='competition_id', right_on='competition_id')
merged_df = merged_df.rename(columns = {'name': 'competition_name'})

merged_df['country_name'] = merged_df['country_name'].fillna('europa')
merged_df
```

Figura 5: merge all'interno di Appearances

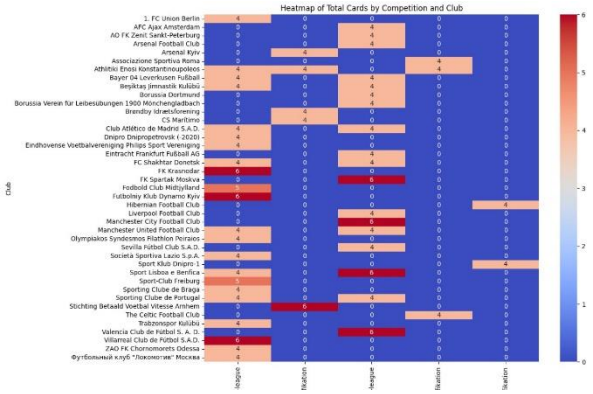


Figura 4:heat map per rappresentare il rapporto tra i club, le competizioni europee e i cartellini

Issues

I problemi che abbiamo avuto nell'ambito dell'analisi dei dati sono sorti sempre per una nostra mancanza per quanto riguarda l'ambito analizzato.

Essendo in presenza di dati tecnici, abbiamo dovuto svolgere diverse ricerche per comprendere il linguaggio utilizzato e poter capire se le nostre analisi fossero corrette. Inoltre non siamo sicuri che le nostre soluzioni siano

totalmente corrette per quanto riguarda determinate analisi il cui risultato non può essere raggiunto tramite pure conoscenze di logica. Seguono alcuni esempi:

- Dati comprensibili tramite logica: sono presenti più giocatori destrorsi che mancini, i giocatori ambidestri segnano più rigori (i portieri non sanno con che piede tireranno).
- Dati per esperti: Danilo è davvero il giocatore con più cartellini? Gli attaccanti sono davvero i giocatori che guadagnano di più?

Inoltre all'interno dell'analisi dei dati abbiamo usato talvolta ChatGPT [1] per la risoluzione di errori o warning.

Requirement

Per quanto riguarda le richieste di analisi di dati, abbiamo svolto una buona analisi trovando gli argomenti e i punti maggiormente di interesse per un tifoso o un giornalista che si appresta a cercare informazioni riguardanti una squadra o un giocatore. Abbiamo inoltre inserito molti grafici per rendere il tutto più comprensibile e visuale.

Limitations

Come per il primo punto, avendo fatto un'analisi modulare, le analisi potrebbero essere state fatte in modo più verboso a causa della divisione in diversi notebook.

Data visualization

Solution

Abbiamo implementato una visualizzazione adatta sia a fan che a esperti tramite l'utilizzo di diversi tipi di grafici. Per i fan abbiamo utilizzato grafici semplici come istogrammi e grafici a torta, mentre invece per gli esperti abbiamo usato line charts, heatmaps, combinantions, violin chart e scatterplot.

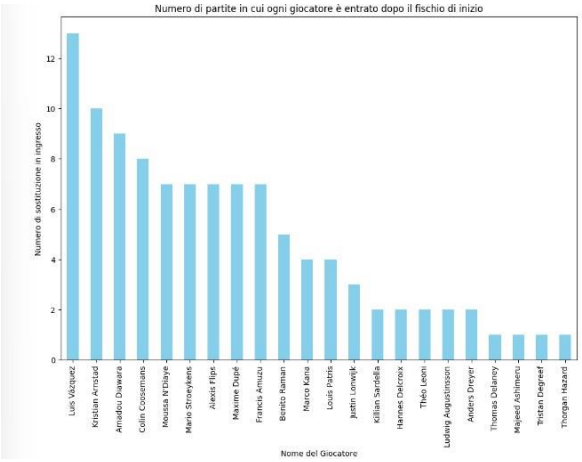


Figura 7:istogramma di Game_lineups

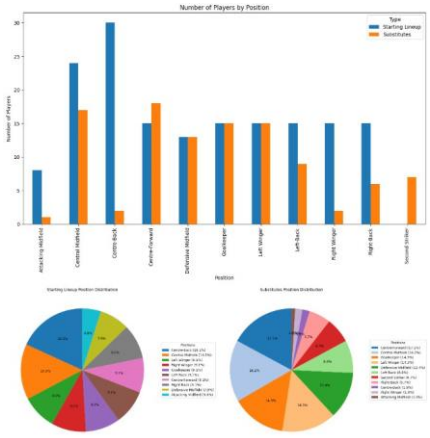


Figura 6:grafico combinato di Game_lineups

Issues

Abbiamo avuto diverse problematiche nello sviluppo dei grafici (soprattutto i più complessi), avendo sempre idea di cosa volevamo mostrare, ma avendo problemi nell'eseguirlo. Per questa parte del progetto abbiamo fatto uso di ChatGPT [1], mostrandogli immagini di grafici che volevamo implementare, i dataset a nostra disposizione e una spiegazione dettagliata di come volevamo rappresentato il grafico.



Figura 8: esempio di utilizzo di ChatGPT. Per soluzione vedi Figura11

Requirement

Per quanto riguarda le richieste di visualizzazione dei dati, abbiamo permesso una visualizzazione molto buona rappresentando i dati sotto diversi formati, alcuni comprensibili da fan e altri da esperti. I grafici sono tutti di facile comprensione e su analisi interessanti. Abbiamo inoltre utilizzato un'intelligenza artificiale per rappresentare il tutto meglio e inserendo spesso delle legende.

Limitations

Non abbiamo utilizzato tutti i tipi di grafici spiegati a lezione, solo quelli che data la nostra analisi pensavamo più appropriata, questo potrebbe essere una limitazione perché potremmo non aver compreso il pieno potenziale di alcuni grafici.

Conclusion

In conclusione possiamo affermare che, pur non essendo esperti nell'ambiente di analisi, è stata possibile una buona analisi dei dati (con relative parti). Le analisi più efficaci sono quelle su dataset dinamici dalle quali, in questo ambito, si possono ricavare informazioni più interessanti e utili.

Division of work

Inizialmente è stato presente un problema nella suddivisione del lavoro dovuta a un nostro errore nella comprensione della consegna. Come può essere visibile nei Git, inizialmente pensavamo fosse necessaria la creazione di un Server in Express anche per la parte di IUM, quindi inizialmente Giulia Bono doveva svolgere l'analisi dei dati e Andrea Argentero il Server in Express. Dopo aver già iniziato lo sviluppo del codice abbiamo notato il nostro errore e quindi Andrea Argentero è subentrato nell'analisi dei dati. La divisione dei dataset da analizzare è la seguente

- Andrea Argentero: Appaerences, Game_events, Game_lineups, Player_Valutations
- Giulia Bono: Club, Club_Games, Competitions(solo pulizia), Games , Players

Il lavoro è diviso equamente, ogni componente ha compiuto sui propri dataset i compiti di pulizia, analisi e visualizzazione.

Extra Information

Non sono necessarie configurazioni particolari per il codice, poiché il Jupyter Notebook (come da richiesta) è già runnato e con tutto visibile. Per completezza abbiamo inserito a inizio codice tutti i pip install che sarebbero necessari per l'esecuzione.

Bibliography

1. OpenAI. "ChatGPT." 2024. https://www.openai.com/chatgpt.